




PREDIKSI HASIL PRODUKSI PADI DI INDIA MENGGUNAKAN ALGORITMA REGRESI LINEAR SEDERHANA

Presented by:

Ilham Pratama Hambali



Latar belakang



Kenapa india?

India merupakan salah satu produsen dan eksportir beras terbesar di dunia, di mana daya saing ekspor beras berperan penting dalam perekonomian nasional dan keseimbangan perdagangan [1].

Apa yang sedang terjadi?

Pangsa sektor pertanian terhadap pendapatan nasional dan total ekspor India menunjukkan tren penurunan dari tahun ke tahun. Kondisi ini menjadi tantangan serius, mengingat sektor pertanian masih menjadi tulang punggung perekonomian India dan menempati posisi strategis dalam perdagangan internasional [3].

Siapa yang berperan penting?

Food and Agriculture Organization (FAO) berperan dalam mendukung pengembangan kebijakan dan pengelolaan pertanian berkelanjutan di India [3].

Solusi yang ditawarkan



Analisis prediksi hasil produksi padi menggunakan algoritma Regresi Linear Sederhana. Hasil prediksi kemudian disajikan dalam bentuk dashboard interaktif agar memudahkan pengguna dalam menganalisis, dan mengambil keputusan terkait produksi padi [4].




Rumusan Masalah

1. Bagaimana memprediksi hasil produksi padi di India sebagai dasar perumusan strategi peningkatan produktivitas dan ketahanan pangan nasional oleh FAO India?
2. Bagaimana mengidentifikasi pola kenaikan atau penurunan produksi padi tahunan selama periode 2010–2015 untuk mendukung penetapan kebijakan dan target produksi yang realistis oleh FAO India?

Tujuan Analisis Data



Memberikan wawasan berupa perkiraan jumlah hasil produksi pertanian (dalam ton) setiap tahun secara kuantitatif sehingga Food and Agriculture Organization (FAO) dapat menggunakan hasil prediksi tersebut untuk membantu mengambil keputusan terkait ketahanan pangan nasional di India.



Menampilkan wawasan mengenai besarnya peningkatan atau penurunan produksi tiap tahun secara kuantitatif sehingga Food and Agriculture Organization (FAO) dapat memahami pola tren persentase perubahan hasil produksi untuk menyusun target produksi atau kebijakan tahun berikutnya secara lebih realistis.



Batasan Masalah

01

Data

Data yang digunakan berasal dari India Agriculture Crop Production Dataset (Kaggle), difokuskan pada komoditas padi (rice) periode 2010–2015 dengan total 4.160 data.

02

Metode Prediksi

Metode prediksi yang diterapkan adalah Regresi Linear Sederhana untuk memodelkan hubungan antara satu variabel independen dan satu variabel dependen.

03


Model yang Dibangun

Model dibangun hanya menggunakan luas lahan (area) sebagai variabel independen untuk memprediksi hasil produksi padi.

Metodologi

CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) adalah metodologi standar terbuka yang menyediakan kerangka kerja terstruktur dan fleksibel untuk memandu proyek data mining dan science, dari pemahaman bisnis hingga penerapan model, melalui enam fase utama: Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, dan Deployment



Bussines Understanding

- **Permasalahan Bisnis**

Kontribusi sektor pertanian terhadap pendapatan nasional dan ekspor India mengalami penurunan dalam jangka panjang, sehingga FAO India membutuhkan analisis berbasis data untuk memprediksi produksi padi dan memahami perubahan produktivitas tahunan.

- **Konteks Keputusan**

FAO India memerlukan dasar pengambilan keputusan yang kuat untuk menyusun kebijakan peningkatan produktivitas padi, pengelolaan sumber daya pertanian, dan menjaga ketahanan pangan nasional.

- **Tujuan Analisis**

Memprediksi produksi padi tahunan dan menganalisis persentase perubahan produksi guna memahami tren produktivitas sebagai dasar perencanaan dan kebijakan pertanian berkelanjutan.

- **Wawasan yang Diharapkan**

Memberikan perkiraan produksi padi serta identifikasi tren kenaikan atau penurunan produktivitas yang dapat digunakan FAO India dalam perencanaan jangka panjang.




Data Understanding

	State_Name	District_Name	Season	Area	Production
0	Andaman and Nicobar Islands	NICOBARS	Autumn	3.5	10.0
1	Andaman and Nicobar Islands	NORTH AND MIDDLE ANDAMAN	Autumn	6791.0	20118.0
2	Andaman and Nicobar Islands	SOUTH ANDAMANS	Autumn	1595.5	3788.0
3	Andhra Pradesh	ANANTAPUR	Kharif	34973.0	102007.0
4	Andhra Pradesh	ANANTAPUR	Rabi	24828.0	69394.0
...	...	...	...	...	...
4155	West Bengal	PURULIA	Summer	516.0	1274.0
4156	West Bengal	PURULIA	Winter	302274.0	730136.0
4157	West Bengal	PURULIA	Autumn	264.0	721.0
4158	West Bengal	PURULIA	Summer	306.0	801.0
4159	West Bengal	PURULIA	Winter	279151.0	597899.0

4160 rows × 5 columns

Data yang digunakan dalam analisis ini berasal dari platform Kaggle melalui India Agriculture Crop Production Dataset <https://www.kaggle.com/datasets/abhinand05/crop-production-in-india>. yang memuat informasi produksi padi di India. Data disaring dengan kriteria Crop = Rice dan Crop_Year = 2010–2015, sehingga diperoleh sebanyak 4.160 data dengan variabel State_Name, District_Name, Season, Area, dan Production. Dataset ini dipilih karena menyediakan data historis yang relevan untuk menganalisis dan memprediksi produksi padi tahunan serta pola perubahan produktivitas, sehingga dapat mendukung pengambilan keputusan strategis FAO dalam memperkuat ketahanan pangan di India.





Data Preparation

a. Ukuran Dataset

(4160, 5)

b. Pengecekan terhadap missing value dan duplikat

```
Missing values:
State_Name      0
District_Name   0
Season          0
Area            0
Production      0
dtype: int64

Duplicate rows:
0
```

c. Statistik Deskriptif


	Area	Production
count	4160.000000	4.160000e+03
mean	51490.807269	1.225512e+05
std	70136.317703	1.877391e+05
min	1.000000	0.000000e+00
25%	3486.750000	5.849645e+03
50%	19707.500000	3.866750e+04
75%	77838.000000	1.634892e+05
max	687000.000000	1.624324e+06



Data Preparation


e. Pengecekan Outlier

Berdasarkan gambar dibawah, Distribusi variabel Area dan Production bersifat right-skewed dengan banyak nilai ekstrem, sehingga boxplot kurang informatif. Oleh karena itu, dilakukan transformasi log untuk memadatkan skala data, mengurangi pengaruh outlier, dan menstabilkan varians agar analisis lebih optimal.



dengan X' merupakan nilai hasil transformasi dan X merupakan nilai asli. Penambahan konstanta 1 digunakan untuk menghindari $\log(0)$ yang tidak terdefinisi.

$$X' = \log(X + 1)$$



Setelah dilakukan log transform, distribusi kedua variabel menjadi lebih simetris dan stabil. Skala Area dan Production menyempit secara signifikan, median menjadi lebih terpusat, serta jumlah outlier berkurang, sehingga boxplot lebih seimbang dan mudah diinterpretasikan.

f. Normalisasi Min-Max

Normalisasi Min-Max diterapkan pada variabel Area dan Production setelah log transform untuk menyetarakan skala data ke dalam rentang 0-1, sehingga data lebih siap digunakan dalam proses analisis dan pemodelan.

$$\hat{x}_{ik} = \frac{x_{ik} - \min(x_k)}{\max(x_k) - \min(x_k)}$$

Data Modeling

Tujuan Utama

Tujuan utama tahap modelling adalah membangun hubungan matematis antara variabel independen (X) dan dependen (Y) agar sistem dapat melakukan prediksi secara kuantitatif.

X = Area

Y = Production

Pembagian data latih dan data uji

Dataset dibagi dengan rasio 80% data latih dan 20% data uji

```
Shape of X_train: (3328, 1)
Shape of X_test: (832, 1)
Shape of y_train: (3328,)
Shape of y_test: (832,)
```

Rumus Persamaan Regresi Linear

$$Y = a + bX$$

Dengan keterangan:

- Y = variabel dependen (nilai yang diprediksi).
- X = variabel independen.
- a = konstanta.
- b = koefisien regresi.

Menghitung regresi linear sederhana

$$X^2, Y^2, XY$$

	x (Area)	y (Production)	x^2	y^2	xy
0	0.06362	0.16768	0.004048	0.028117	0.010668
1	0.63783	0.69294	0.406827	0.480166	0.441978
2	0.52424	0.57619	0.274828	0.331995	0.302062
3	0.76640	0.80646	0.587369	0.650378	0.618071
4	0.73952	0.77952	0.546890	0.607651	0.576471
...	...	...	...	...	...
3323	0.71073	0.75396	0.505137	0.568456	0.535862
3324	0.71093	0.75233	0.505421	0.566000	0.534854
3325	0.71286	0.75911	0.508169	0.576248	0.541139
3326	0.85068	0.87767	0.723656	0.770305	0.746616
3327	0.84962	0.87771	0.721854	0.770375	0.745720
3328 rows x 5 columns					
--- Total dari masing-masing kolom ---					
Total x (Area)		: 2249.50144			
Total y (Production)		: 2317.28589			
Total x^2		: 1630.22503			
Total y^2		: 1708.71799			
Total xy		: 1664.58923			

Data Modeling

Menghitung konstanta (a) dan (b)

Menghitung konstanta (a):

Rumus:

$$a = \frac{(\sum y)(\sum x^2) - (\sum x)(\sum xy)}{n(\sum x^2) - (\sum x)^2}$$

$$a = \frac{(2317.285733)(1630.225181) - (2249.501423)(1664.58916)}{3328(1630.225181) - (2249.501423)^2}$$

$$a = 0,09093$$

```
--- Menghitung Konstanta a (Intercept) ---  
Nilai a      : 0.09093
```

Menghitung konstanta (b):


Rumus:

$$b = \frac{n(\sum xy) - (\sum x)(\sum y)}{n(\sum x^2) - (\sum x)^2}$$

$$b = \frac{3328(1664.58916) - (2249.501423)(2317.285733)}{3328(1630.225181) - (2249.501423)^2}$$

$$b = 0,89561$$

```
Nilai b      : 0.89561
```



Membuat model persamaan Regresi Linear Sederhana

Rumus:

$$Y = a + bX$$

Perhitungan:

```
Persamaan Regresi Linear Sederhana:  
Production = 0.09093 + (0.89561 * Area)
```

Evaluation

a. Mean Squared Error (MSE)

MSE adalah rata-rata dari selisih kuadrat antara nilai aktual dan nilai prediksi:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

hasil perhitungan Mean Squared Error (MSE) sebagai berikut:

Mean Squared Error (MSE): 0.0005036783383037691

b. Root Mean Squared Error (RMSE)

RMSE adalah akar dari MSE dan menunjukkan deviasi rata-rata dari prediksi terhadap nilai aktual dalam satuan aslinya:

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

hasil perhitungan Root Mean Squared Error (RMSE) sebagai berikut:

Root Mean Squared Error (RMSE): 0.02244277920186734

c. Mean Absolute Error (MAE)

MAE adalah rata-rata dari selisih absolut antara nilai aktual dan nilai prediksi:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Selisih absolut dihitung untuk setiap observasi. hasil perhitungan Mean Absolute Error (MAE) sebagai berikut:

Mean Absolute Error (MAE): 0.018693909592221555

d. R-Squared

R² adalah ukuran seberapa baik nilai prediksi cocok dengan nilai aktual:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Dimana :
= rata rata dari nilai aktual

Hasil perhitungan R-Squared sebagai berikut:

R-squared (R²): 0.986689218219639



e. Prediksi Dengan Data Baru

Data Luas Panen (Area) untuk prediksi 5 tahun ke depan wajib melewati tahap Log Transform dan Normalisasi Min-Max. Hal ini dilakukan agar format data input baru selaras dengan data latih yang digunakan pada model regresi sebelumnya.

Year	Area(x)
2016	100
2017	150
2018	200
2019	300
2020	350

1. Log Transform pada Area

Untuk menstabilkan skala dan mengurangi efek outlier, nilai Area terlebih dahulu ditransformasikan ke bentuk log. Hasil log transform adalah:

Inverse_Scaled_Log_Production	
0	5.241033
1	5.645110
2	5.932498
3	6.338229
4	6.492638

2. Normalisasi Min Max

Selanjutkan nilai log Area tersebut dinormalisasikan hasilnya sebagai berikut:

Predicted_Scaled_Log_Production	
0	0.366490
1	0.394746
2	0.414843
3	0.443214
4	0.454011

3. Prediksi Menggunakan Model Regresi

Setelah data berada pada skala yang sesuai, nilai Area (x) dimasukkan ke persamaan regresi linear sederhana:

$$Y=a+bX$$

Dengan nilai model sebagai berikut:

- $a = 0.09093095529$
- $b = 0.8956062411$
- X = nilai Area yang telah dinormalisasi (x)

sehingga bentuk persamaannya adalah:

$$Y=0.09093095529+0.8956062411(X)$$

Hasil dari persamaan tersebut masih berada pada skala transformasi sehingga dilakukan proses inverse Min-Max dan Invers log untuk mengembalikan nilai ke skala produksi asli

Area	Predicted_Scaled_Log_Production	Inverse_Scaled_Log_Production	Actual_Predicted_Production_Tons
0 0.307680	0.366490	5.241033	187.865040
1 0.339229	0.394746	5.645110	281.904547
2 0.361668	0.414843	5.932498	376.095482
3 0.393346	0.443214	6.338229	564.793500
4 0.405402	0.454011	6.492638	659.262759


4. Hasil Akhir Prediksi Produksi

Nilai produksi lima tahun ke depan yang telah dikonversi kembali ke satuan aslinya adalah:

Actual_Predicted_Production_Tons	Year	Percentage
187.865040	2016	-
281.904547	2017	50.06%
376.095482	2018	33.41%
564.793500	2019	50.17%
659.262759	2020	16.73%



Deployment



Hasil analisis dideploy untuk mendukung FAO India dalam perumusan kebijakan ketahanan pangan. Model prediksi diimplementasikan melalui dashboard interaktif Streamlit yang menampilkan estimasi produksi padi tahunan dan tren perubahannya secara visual, sehingga memudahkan penetapan target dan strategi peningkatan produktivitas berbasis data.

HASIL ANALISIS

Prediksi produksi padi di India selama lima tahun menunjukkan tren peningkatan seiring bertambahnya luas area tanam. Produksi naik signifikan dari 187,87 ton (2016) menjadi 659,26 ton (2020), meskipun persentase pertumbuhan tahunan cenderung menurun dan mulai stabil. Hal ini menegaskan adanya korelasi langsung antara luas area tanam dan produksi, serta pentingnya analisis laju pertumbuhan untuk memahami tren jangka panjang. Temuan ini dapat dimanfaatkan FAO India untuk menetapkan target produksi yang realistis, mengoptimalkan alokasi lahan, dan menyusun strategi peningkatan produktivitas guna memperkuat ketahanan pangan nasional.




KESIMPULAN



Analisis ini menghasilkan model Regresi Linear Sederhana yang sangat akurat untuk memprediksi produksi padi di India, dengan koefisien determinasi sebesar **0,987** yang menunjukkan bahwa luas area tanam berpengaruh dominan terhadap produksi. Nilai kesalahan yang rendah (MAE 0,019 dan RMSE 0,022) menegaskan keandalan model. Hasil prediksi menunjukkan tren peningkatan produksi yang konsisten dari 2016 hingga 2020, meskipun laju pertumbuhan tahunan berfluktuasi. Temuan ini dapat menjadi dasar yang kuat bagi FAO India dalam perencanaan kebijakan pertanian berkelanjutan, penetapan target produksi yang realistis, dan penguatan ketahanan pangan nasional.

DAFTAR PUSTAKA

- [1] A. K. Yadav and U. Chattopadhyay, "India's Rice Competitiveness and Its Determinants: An Empirical Analysis," *Journal of Agricultural and Applied Economics* , 2025, doi: 10.1017/aae.2025.2.
- [2] V. Sellam and E. Poovammal, "Prediction of crop yield using regression analysis," *Indian J Sci Technol*, vol. 9, no. 38, 2016, doi: 10.17485/ijst/2016/v9i38/91714.
- [3] Food and A. O. of the United Nations, "Worldwide Offices - Food and Agriculture Organization of the United Nations," 2024.
- [4] A. Surya Harahap and J. Sihar Manurung, "Optimal: Jurnal Ekonomi dan Manajemen Volume," vol. 5, pp. 702–713, 2025, doi: 10.55606/optimal.v5i4.8259.
- [5] A. A. Suryanto, A. Muqtadir, and S. Artikel, "PENERAPAN METODE MEAN ABSOLUTE ERROR (MEA) DALAM ALGORITMA REGRESI LINEAR UNTUK PREDIKSI PRODUKSI PADI Info Artikel : ABSTRAK," no. 1, p. 11, 2019.





Terima Kasih !

